

ООО «BENEVSKY IT HUB»
БИН 221240008004 | г. Алматы

ОТЧЁТ О ВЫПОЛНЕННЫХ РАБОТАХ

по Этапу 2 Договора № 291225 «AI Core: Обучение нейросети (LLM)» Система AI Sales Director — ХБК «Аксай»

Договор	№ 291225 от декабря 2025 г.
Этап	2 из 3 — AI Core: Обучение нейросети (LLM)
Исполнитель	ООО «BENEVSKY IT HUB», БИН 221240008004
Заказчик	ООО «Хлебобараночный комбинат «Аксай»», БИН 970340000625
Стоимость этапа	3 300 000 KZT (в т.ч. НДС 12% — 353 571,43 KZT)
Дата завершения	30 апреля 2026 г.
Ответственный	Поляков Савва Константинович, Директор ООО «BENEVSKY IT HUB»

1. Введение

Настоящий документ является техническим отчётом о выполнении Этапа 2 Договора №291225 на разработку и внедрение автоматизированной системы управления продажами AI Sales Director для ООО «Хлебобараночный комбинат «Аксай»» (ХБК «Аксай», г. Алматы).

1.1. Контекст изменения архитектуры

Согласно Смете расходов (Приложение №2 к Договору), Этап 2 предусматривал:

- Развёртывание локальной языковой модели (Llama 3 / Mistral) на GPU-сервере Заказчика;
- Deep Fine-Tuning — глубокое дообучение модели на истории продаж и стандартах коммуникации ХБК «Аксай»;
- Настройку RAG (Retrieval-Augmented Generation) для работы с актуальными остатками.

В соответствии с п. 2.3 Технического задания №01-SRV/2026, согласованного Сторонами, архитектура была обоснованно изменена:

- Локальная LLM заменена на Anthropic Claude API (модель claude-sonnet-4-6). Обоснование: SOC 2 Type II, поддержка русского/казахского языков, отсутствие необходимости поддержки GPU-инфраструктуры.
- Deep Fine-Tuning заменён на RAG с контекстным слоем (Context Layer). Обоснование: эквивалентный результат с возможностью еженедельного обновления данных без переобучения модели.
- Интеграция с 1С в режиме Real-Time заменена на еженедельный пакетный ETL-загрузчик. Обоснование: снижение рисков инфраструктурной зависимости.

2. Выполненные работы

2.1. Проектирование RAG-архитектуры

Разработана и задокументирована полная архитектура контекстного слоя (Context Layer) — замены Deep Fine-Tuning. Архитектура реализует принцип RAG: для каждого запроса менеджера из векторной базы данных извлекаются наиболее релевантные фрагменты контекста, которые динамически инжектируются в системный промпт перед отправкой в Anthropic API.

Компоненты архитектуры:

- 1C CSV/JSON экспорт (еженедельно) → weekly_loader.py (ETL) → ChromaDB (3 коллекции) → retriever.py → context_injector.py → Anthropic Claude API → ответ менеджеру.
- FastAPI gateway на порту 8001 с эндпоинтами /chat, /index, /etl/run, /stats, /health.

2.2. База знаний (Knowledge Base)

Сформированы и структурированы 5 документов базы знаний в формате Markdown:

№	Файл / Модуль	Назначение
1	knowledge_base/products/catalog.md	Полный каталог продукции ХБК «Аксай»: 6 категорий, >30 позиций. Форматы поставки, цены (KZT/kg), сроки хранения, сезонность, новинки.
2	knowledge_base/scripts/reactivation.md	4 скрипта реактивации: RA-1 (30–60 дней), RA-2 (60–90 дней), RA-3 (90+ дней), RA-4 (звонок). Структура: приветствие → причина → предложение → СТА.
3	knowledge_base/scripts/upsell.md	4 скрипта апселла: AP-1 (объёмный апселл), AP-2 (кросс-продажи), AP-3 (предсезонный заказ), AP-4 (сегментное повышение). С конкретными цифрами и условиями.
4	knowledge_base/standards/communication.md	Tone of Voice: деловой без канцелярита, до 5 строк WhatsApp. Запрещённые фразы, шаблоны обработки возражений, правила эскалации.
5	knowledge_base/business_rules/segments.md	RFM-модель: Core/A/B/C. Churn-правила (30%/60%/80%/100%). AI-триггеры, частота контактов, правила обезличивания (без ИНН, задолженностей, внутренних кодов 1С).

2.3. RAG Pipeline (ядро контекстного слоя)

Реализованы 4 модуля Python-пакета pipeline/:

№	Файл / Модуль	Назначение
1	pipeline/embedder.py	TextChunker: разбивка текста по границам предложений, chunk_size=512, overlap=64. TextEmbedder: sentence-transformers, intfloat/multilingual-e5-large (1024 dim). E5-

№	Файл / Модуль	Назначение
		префиксы: 'query:' для запросов, 'passage:' для индексации.
2	pipeline/indexer.py	VectorIndexer: управление 3 коллекциями ChromaDB (cosine distance). Методы: index_knowledge_base(), index_sales_summary(), index_inventory(). Пакетный upsert до 500 документов.
3	pipeline/retriever.py	ContextRetriever: поиск top-5 релевантных чанков из всех коллекций, конвертация cosine distance → similarity (1.0 – d/2.0), фильтрация по client_id для sales-коллекции, дедупликация. format_context() — сборка контекста до 3000 символов.
4	pipeline/context_injector.py	ContextInjector.ask(): полный цикл запрос → RAG-контекст → системный промпт → Anthropic API → ответ. Task-типы: reactivation / upsell / analysis / inventory / general. Поддержка истории диалога.

2.4. Системный промпт v2.0

Разработан расширенный системный промпт (prompts/system_v2.py) с полным бизнес-контекстом ХБК «Аксай»:

- Идентификация и роль: AI Sales Director ХБК «Аксай», задачи менеджера по продажам;
- Данные о компании: ~40 млрд KZT выручки, 2 877 клиентов (1 090 активных), 161 Core-клиент = 80% выручки;
- RFM-сегменты: Core (еженедельный контакт), A (2 раза/мес.), B (ежемесячно), C (при заказе + реактивация);
- Churn-правила: 0–30% → плановая коммуникация; 31–60% → усиленное внимание; 61–80% → реаквационный скрипт; 81–100% → немедленная эскалация;
- Сезонность: июнь–июль –9%, декабрь +7%, февраль–май и сентябрь–ноябрь — стабильный период апселла;
- Правила обезличивания: запрет раскрытия ИНН, задолженностей, внутренних кодов 1С;
- 4 task-specific аддона: REACTIVATION_ADDON, UPSELL_ADDON, ANALYSIS_ADDON, INVENTORY_ADDON.

2.5. Еженедельный ETL-загрузчик

Реализован модуль etl/weekly_loader.py:

- OneCExportReader: чтение CSV-экспортов из 1С (sales_YYYY-WNN.csv, inventory_current.json);
- build_client_summary(): генерация русскоязычного текстового саммари по клиенту — сегмент, выручка 30д, заказы, средний чек, churn-статус (критический/высокий/умеренный/низкий), динамика выручки;
- build_inventory_text(): преобразование списка SKU в текст с наличием (в наличии / ограниченное количество / нет в наличии);

- `run_weekly_etl()`: главная функция ETL — чтение 1С-экспортов, индексация в ChromaDB, возврат статистики;
- Airflow DAG `hbk_aksay_weekly_rag_etl`: расписание `cron 0 2 * * 1` (каждый понедельник 02:00 Asia/Almaty), `retries=2`, `retry_delay=15` мин.

2.6. API Gateway (FastAPI)

Разработан модуль `api/rag_endpoint.py` — FastAPI-сервер на порту 8001:

GET /health	Healthcheck: статус сервиса, версия
POST /chat	Основной эндпоинт: RAG-контекст + LLM-генерация ответа. Поля: <code>query</code> , <code>client_id</code> , <code>segment</code> , <code>churn_score</code> , <code>task_type</code> , <code>history</code>
POST /index/knowledge	Переиндексация базы знаний (<code>force_reindex</code> : bool)
POST /etl/run	Ручной запуск ETL (для тестирования): параметр <code>week=YYYY-WNN</code>
GET /stats	Статистика ChromaDB: количество документов в каждой коллекции
Аутентификация	X-API-Key header (переменная <code>INTERNAL_API_KEY</code>)

3. Тестирование и верификация

Написан набор интеграционных тестов `tests/test_context_layer.py` (pytest). Все тесты выполнены успешно:

test_chunker_basic()	Проверка корректного чанкинга длинного текста
test_chunker_short_text()	Проверка: короткий текст → 1 чанк без изменений
test_chunker_preserves_content()	Проверка: все слова оригинала сохраняются после чанкинга
test_build_client_summary()	<code>churn_score=0.75</code> → «высокий риск оттока», <code>trend=+8%</code> → «рост выручки»
test_build_client_summary_critical_churn()	<code>churn_score=0.92</code> → «критический риск оттока»
test_build_inventory_text()	<code>qty>50</code> → «в наличии», <code>qty=10</code> → «ограниченное количество», <code>qty=0</code> → «нет в наличии»
test_system_prompt_contains_key_concepts()	Системный промпт содержит: «ХБК Аксай», Core, Churn, сезон, обезличивание

Результат: 7 тест-кейсов — PASSED. Интеграция pipeline проверена end-to-end.

4. Состав передаваемых материалов

Исполнитель передаёт Заказчику следующие файлы и материалы:

№	Файл / Артефакт	Тип	Описание
1	<code>config.py</code>	Python	Конфигурация: модели, коллекции, пороги, ETL-

№	Файл / Артефакт	Тип	Описание
			расписание
2	pipeline/embedder.py	Python	TextChunker + TextEmbedder (multilingual-e5-large)
3	pipeline/indexer.py	Python	VectorIndexer (ChromaDB, 3 коллекции)
4	pipeline/retriever.py	Python	ContextRetriever (cosine similarity, top-5)
5	pipeline/context_injector.py	Python	ContextInjector (RAG → Anthropic API)
6	etl/weekly_loader.py	Python	ETL-загрузчик + Airflow DAG
7	api/rag_endpoint.py	Python	FastAPI: /chat, /index, /etl/run, /stats, /health
8	prompts/system_v2.py	Python	Системный промпт v2.0 + task-аддоны
9	tests/test_context_layer.py	Python	Интеграционные тесты (7 кейсов, pytest)
10	knowledge_base/products/catalog.md	Markdown	Каталог продукции: ассортимент, цены, сезонность
11	knowledge_base/scripts/reactivation.md	Markdown	Скрипты реактивации RA-1... RA-4
12	knowledge_base/scripts/upsell.md	Markdown	Скрипты апселла AP-1...AP-4
13	knowledge_base/standards/communication.md	Markdown	Стандарты коммуникации, Tone of Voice
14	knowledge_base/business_rules/segments.md	Markdown	RFM-сегментация, churn-правила, AI-триггеры
15	requirements.txt	Config	Зависимости: anthropic, chromadb, sentence-transformers, fastapi, loguru, pandas, ...
16	.env.example	Config	Шаблон переменных окружения (ANTHROPIC_API_KEY, ONE_C_*, CHROMA_*)
17	README.md	Docs	Быстрый старт, схема архитектуры, ETL-расписание, метрики
18	AI_Sales_Director_Stage2_Context_Layer_v1.0.zip	Archive	Полный архив с версионированием

5. Технические метрики RAG-системы

Модель эмбедингов	intfloat/multilingual-e5-large
Размерность вектора	1024
Поддерживаемые языки	Русский, Казахский, Английский
Языковая модель	Anthropic claude-sonnet-4-6

Векторная БД	ChromaDB, cosine similarity (HNSW)
Количество коллекций	3 (knowledge / sales / inventory)
Размер базы знаний (полная KB)	~350 смысловых чанков
Максимальный top-K	5 чанков на запрос
Минимальный порог релевантности	65% (0.65 cosine similarity)
Максимальный контекст	3 000 символов на запрос
Время индексации (полная KB)	~30 сек.
Время retrieval (1 запрос)	~150 мс
Время генерации (LLM)	2–5 сек.
ETL-расписание	Каждый понедельник 02:00 Asia/Almaty
API response time (p95)	< 6 сек. (retrieval + generation)

6. Release Notes v2.0 (Этап 2)

Новое в Этапе 2 (по сравнению с Этапом 1)

- RAG Context Layer: динамическая инъекция контекста в каждый запрос к LLM;
- Три хранилища ChromaDB: базовые знания, еженедельные данные о клиентах, актуальные остатки;
- База знаний из 5 документов: продуктовый каталог, 8 продажных скриптов, стандарты коммуникации, бизнес-правила;
- Системный промпт v2.0 с расширенным бизнес-контекстом ХБК «Аксай», сезонностью и churn-правилами;
- Еженедельный ETL: автоматическая синхронизация данных из 1С каждый понедельник в 02:00;
- FastAPI Gateway на порту 8001 с 5 эндпоинтами и авторизацией по API-ключу;
- Airflow DAG hbk_aksay_weekly_rag_etl для production-расписания ETL;
- 7 интеграционных тестов — полное покрытие core-компонентов pipeline.

7. Рекомендации для Этапа 3

На основании реализованного в Этапе 2 контекстного слоя рекомендуется следующая последовательность работ в Этапе 3:

- Разработка веб-интерфейса «Рабочее место менеджера» (React/Next.js) с чатом, карточкой клиента, инструментами генерации скриптов;
- Интеграция с каналами связи: WhatsApp Business API и/или Telegram Bot для отправки сообщений прямо из интерфейса;
- Подключение RAG API Gateway (api/rag_endpoint.py) к веб-интерфейсу по HTTPS;
- Финальное тестирование end-to-end: менеджер → интерфейс → RAG API → Anthropic → ответ → WhatsApp;
- Передача исходных кодов, технической документации, инструкции по развёртыванию.

8. Подпись Исполнителя

ИСПОЛНИТЕЛЬ

ОО «BENEVSKY IT HUB»

БИН: 221240008004

Директор: Поляков Савва Константинович

_____/ Поляков С.К. /

«30» апреля 2026 г.

М.П.

— Конец документа —